

Physics Informed Neural Network

Buckley Laverette

Выполнил: Комаров Николай
Группа: 5040102/40201

$$\text{Buckley – Laverette eq.: } \frac{\partial S_w(x, t)}{\partial t} + \frac{\partial f(S_w(x, t))}{\partial x} = 0$$

Начальные Условия: $S_w(x, 0) = S_0$

Граничные Условия: $S_w(a, t) = S_a,$

$$S_w(b, t) = S_b$$

- Отсутствует аналитическое решение
- Численные методы – имеют высокую сложность реализации, требуют тонкой настройки
- Как получить решение ???

Проблематика

Что мы знаем – Начальное распределение и Граничные Условия. Всё, что между ними – неизвестно




Рис. 1 Начальное условие





Рис. 2 Граничные условия

Цели

- Построить *предиктивную модель* на основе методов машинного обучения для вычисления значений водонасыщенности на координатном промежутке
- Использовать для нахождения значений функции заданные *начальные* и *граничные* условия
- Реализовать *web*-приложение

Какие подходы использовать

- Стандартные методы машинного обучения не подходят
значения функции в промежутке $[x1, x2]$ неизвестны – обучаться не на чем
- Нейронные сети:



Нормализация

$x = [a;b] \rightarrow [0;1]:$

```
normalized_data[col] = (data[col] - min_val) / (max_val - min_val)
```

Генерация коллокационных точек

$\text{Data} = \{ (x=0, t=0) ; (x=1, t=1) \} \rightarrow \{ (x=0, t=0) ; (x=0.1, t=0) \dots (x=0.1, t=0.1) \dots (x=1, t=1) \}$

```
lb = X_setka.min(axis=0) # [x=0, t=0]
```

```
ub = X_setka.max(axis=0) # [x=1, t=1]
```

```
X_collocate = lb + (ub - lb) * lhs(2, num_points)
```

Архитектура Нейронной Сети

Нейронная сеть с последовательными слоями





Рис. 1 Архитектура Нейронной Сети

Архитектура Нейронной Сети

Преобразование данных




Линейное преобразование данных для оптимальной работы нейронов

$$\{ (0,0) \dots (0,1) \} \rightarrow \{ (-1,-1) \dots (1,1) \}$$


```
self.u_model.add(tf.keras.layers.Rescaling(scale=2.0, offset=-1.0))
```

Активация нейронов




```
for width in layers[1:-1]:  
    self.u_model.add(tf.keras.layers.Dense(  
        width,  
        activation=tf.nn.tanh,  
        kernel_initializer=tf.keras.initializers.GlorotNormal(),  
        bias_initializer='zeros'))
```

“хорошие” производные →



Архитектура Нейронной Сети

Ошибка дифф. уравнения



$$\frac{\partial U_{w_predict}(x, t)}{\partial t} + \frac{\partial f(U_{w_predict}(x, t))}{\partial x} = Loss_{equation} \approx 0$$

f_model:

```
u = self.u_model(X_f)
```

```
u_t = tape.gradient(u, self.t_f)
```

```
f_u_x = tape.gradient(f_u, self.x_f)
```

```
return u_t + f_u_x
```

```
Loss_eq = tf.reduce_mean(tf.square(self.f_model()))
```

Ошибка по Н.У. и Г.У.



Используем MSE (среднеквадратичная ошибка):

```
u_pred = self.u_model(X_u) # полученные зн-я из модели
```

```
data_loss = tf.reduce_mean(tf.square(u - u_pred)) # u - зн-я  
водонасыщенности в Н.У. и Г.У.
```

Архитектура Нейронной Сети

Ошибка для обучения Нейронной сети



$$\text{Loss} = \text{weight_eq} * \text{Loss_equation} + \text{weight_data} * \text{Loss_Data}$$

$$\text{total_loss} = \text{loss_weights}[0] * \text{Loss_Data} + \text{loss_weights}[1] * \text{loss_equation}$$

Обучение Нейронной сети

Оптимизатор Adam

коррекция моментов:

обновление весовых коэффициентов:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla \text{LOSS}$$
$$a_t = \beta_2 a_{t-1} + (1 - \beta_2) (\nabla \text{LOSS})^2$$

$$\tilde{m}_t = \frac{m_t}{1 - \beta_1^t}$$
$$\tilde{a}_t = \frac{a_t}{1 - \beta_2^t}$$

$$w_t = w_{t-1} - \eta \frac{\tilde{m}_t}{\sqrt{\tilde{a}_t} + \epsilon}$$

η – шаг обучения

m_t - скользящее среднее относительно среднего градиента

a_t - скользящее среднее относительно среднеквадратичного градиента

β_1, β_2 - коэффициенты импульса

Архитектура Нейронной Сети

Обучение Нейронной сети


Уменьшение шага обучения. Экспоненциальное затухание

$$\eta = \eta_0 * (\text{decay_rate})^{\frac{\text{step}}{\text{decay_step}}}$$

```
lr_schedule = tf.keras.optimizers.schedules.ExponentialDecay(  
    initial_learning_rate=1e-2,  
    decay_steps=2000,  
    decay_rate=0.95)
```

Параметры оптимизатора Адам

```
tf_optimizer = tf.keras.optimizers.Adam(  
    learning_rate=lr_schedule,  
    beta_1=0.9,  
    beta_2=0.999,  
    epsilon=1e-7)
```



Архитектура Нейронной Сети

Обучение Нейронной сети

На каждом шаге обучения получаем ошибку, берем градиент и обновляем веса в нейронах согласно конфиг-ии оптимизатора:

```
def train_step(self, X_u, u, loss_weights=None):  
    with tf.GradientTape() as tape:  
        total_loss, data_loss, pde_loss = self.loss_fn(X_u, u, loss_weights)  
  
        grads = tape.gradient(total_loss, self.__wrap_training_variables())  
  
        self.optimizer.apply_gradients(zip(grads,  
        self.__wrap_training_variables()))  
  
    return total_loss, data_loss, pde_loss
```

Движемся по эпохам обучения:

```
for epoch in range(tf_epochs):  
  
    # Определяем веса ошибок для текущей эпохи  
    current_weights = get_loss_weights_for_epoch(epoch,  
    loss_weights_schedule)  
  
    total_loss, data_loss, pde_loss = self.train_step(X_u, u,  
    current_weights)
```

Компоненты приложения

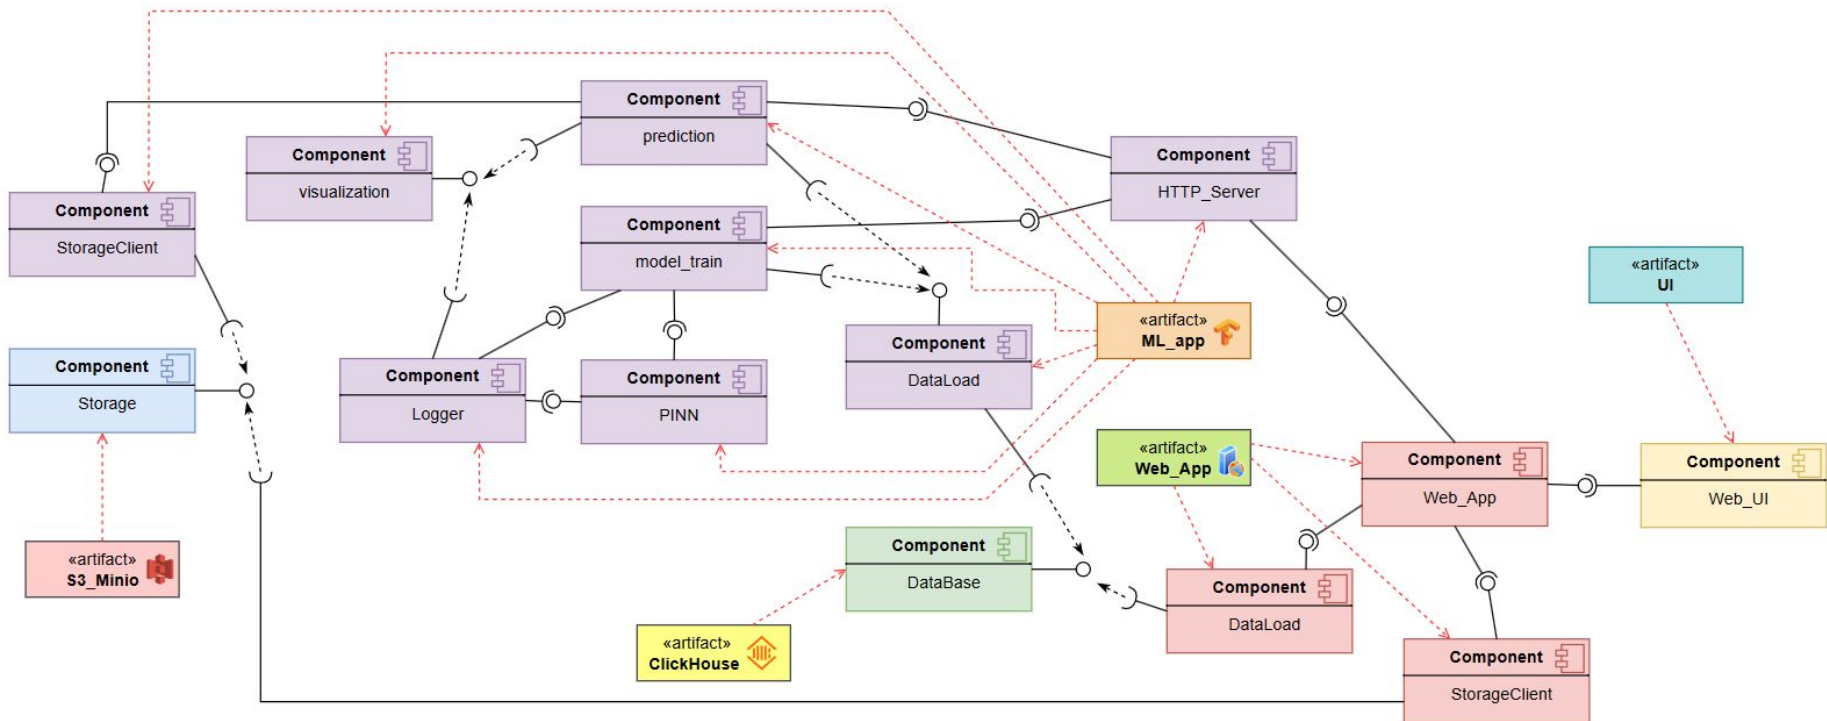


Рис. 2 Компоненты

Архитектура Приложения

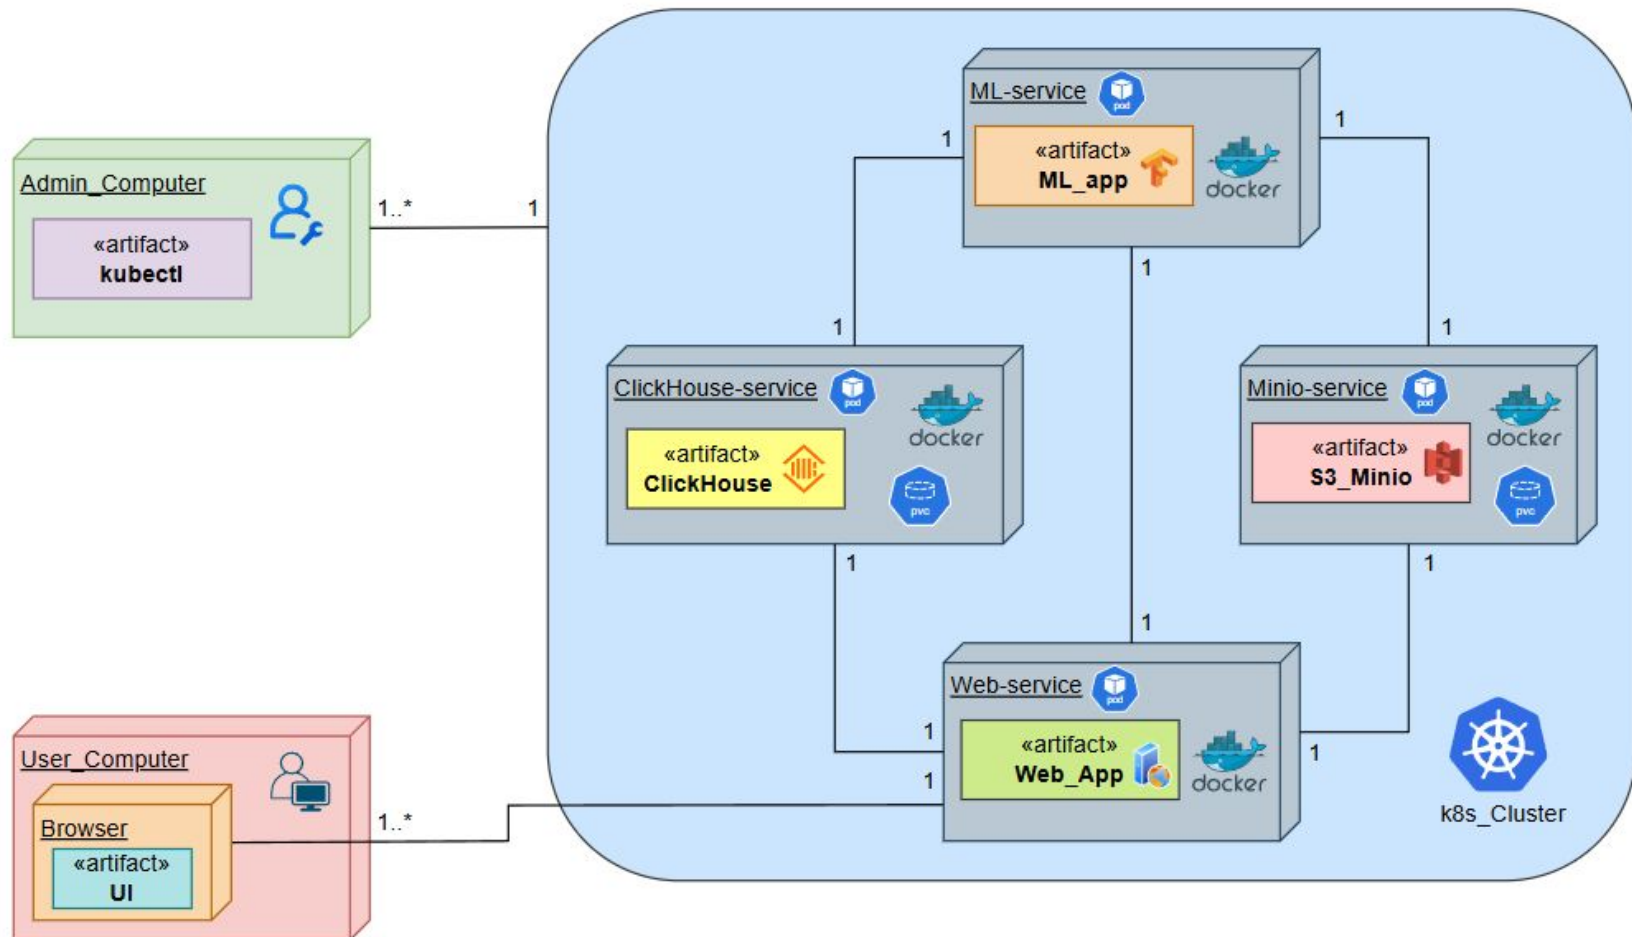


Рис. 3 Размещение

Результаты

Графики ошибки по эпохам




Рис. 4 Размещение
5000 эпох
5 слоев, 10 нейронов




Рис. 5 Размещение
5000 эпох
10 слоев, 20 нейронов

Результаты

Полученная функция распределения




Рис. 6 График распределения предсказанной функции в момент времени $t=0.5$

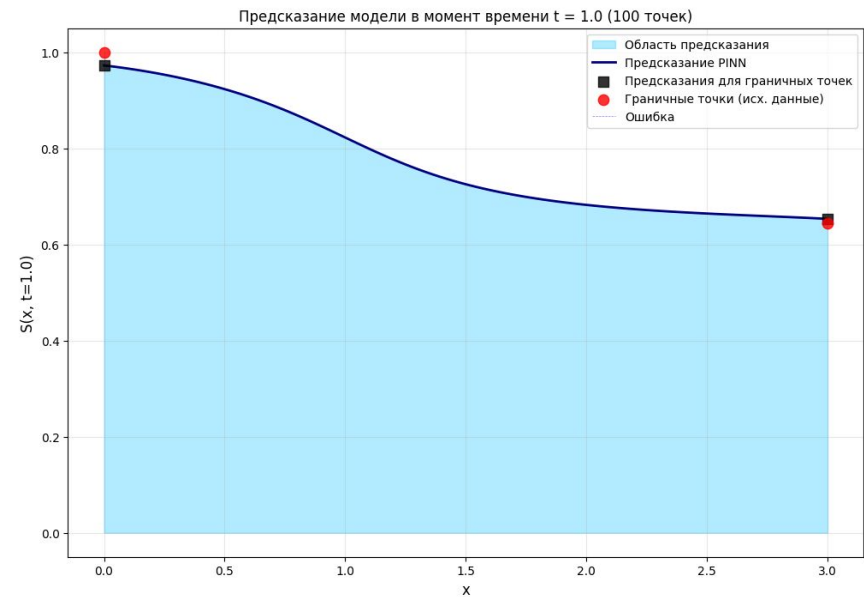


Рис. 7 График распределения предсказанной функции в момент времени $t=1.0$

Результаты

Результаты для известного распределения




Рис. 8 График распределения
предсказанной функции в момент
времени $t=0.5$




Рис. 9 График распределения
предсказанной функции в момент
времени $t=0.5$

ИСТОЧНИКИ

Tensorflow:

- https://www.tensorflow.org/api_docs/python/tf/keras/Sequential

Preparation Data:

- <https://www.geeksforgeeks.org/data-analysis/different-types-of-data-sampling-methods-and-techniques/>
- <https://datasciencegenie.com/latin-hypercube-sampling-vs-monte-carlo-sampling/>

PINN Buckley-Leverette:

- [\(PDF\) Data-Free and Data-Efficient Physics-Informed Neural Network Approaches to Solve the Buckley-Leverett Problem](#)
- https://www.researchgate.net/publication/346559662_Buckley-Leverett_Theory_for_Two-Phase_Immiscible_Fluids_Flow_Model_with_Explicit_Phase-Coupling_Terms

K8s:

- <https://kubernetes.io/docs/concepts/workloads/controllers/deployment/>

ClickHouse:

- <https://clickhouse.com/docs/integrations/python>

S3 Minio:

- <https://pypi.org/project/minio/>

FastApi:

- <https://fastapi.tiangolo.com/>